

报告编号 No. 2026-0921-K3

测量日期 2026-09-21

计量对象 Kimi 会员额度计费系统 (Allegretto ¥199/月)



计 量 校 准 证 书

Kimi 会员额度计费黑盒实测

一根只显示百分比的进度条背后：月度额度池的真实价值、Code 与 Work 两套未公示的费率、以及一次 41.9 分钟的任务如何蒸发掉月度额度的 $\approx 19.5\%$ 。

测量与撰写：Kimi K3 模型 (k3-agent, 于 DeepSeek Harness 代理框架) · 受控实验执行与审校：人类付费用户

—— 被计费的模型，测量了计费它自己的系统 ——

¥1,000 月度额度池的 API 标价锚点 (1% $\equiv$ ¥10, 实测推算)	22× 缓存计费差距 Code ¥0.08/M vs Work ¥1.82/M	2.6× Work 输出加价 实测 ¥263~272/M (官方 ¥105)	$\approx 19.5\%$ 一次 41.9 分钟的 Work 任务 蒸发的月度额度 (计数器口径)
---	---	--	---

■ 机制速览 · 先读这一节

Kimi 会员计费的三层结构

先把计费这件事本身说清楚，再看测量结果。

01 你付的钱

¥199/月，固定。用多用少都是这个价，不超收、不退还。

02 你得到的东西

一根 0~100% 的百分比条。官方只公布档位间的相对倍率和粗略的任务数估算；没有绝对 token 数，没有人民币折算，没有分项费率。

03 本报告测出的换算

1% = 官方 API 标价 ¥10，全池 = ¥1,000 标价。下文所有的"¥"都指这个标价口径，不是你的实付。

04 扣费的方式

每次调用：tokens × 通道费率，折算成百分比从池中扣除（0.01% 取整，单次最低 0.01%）。Code 与 Work 是两套不同的费率——这就是本报告测出来的东西。

为什么同一件事有两种价格？ 因为第 04 条的"通道费率"从未公示。同一个 K3 模型、同一池额度，走 Code 通道便宜，走 Work 通道贵——缓存一项相差 22 倍。下面把两套费率逐一校准。

算例 · 一次扣费的诞生（受控实验 W2 实录）

输出 1,055 tok × Work 输出价 ¥270/M	¥0.28
缓存读 29,184 tok × Work 缓存价 ¥1.82/M	¥0.05

两个"钱"的口径，别混

标价口径（口径 A）：池子的内部记账单位。说"这次扣费 ¥1.10"，意思是"相当于 ¥1.10 的官方 API 标价"——用来比较通道与任务的相对成本。本页的 ¥ 默认此口径。

新输入 186 tok $\times$ Work 输入价 ¥37.2/M ¥0.01

合计（标价口径）→ ÷¥10 换算 → ¥0.34 →
量化取整 0.034%


从池中实扣 0.03%

实付口径（口径 B）：你真实付出的固定 ¥199/月。走 Code 通道，这 ¥199 约买到 ¥2,540 标价算力；走 Work+iFinD，只买到约 ¥397（见购买力测算）。

■ 消耗曲线

一天的两种速度

计费周期当天重置。上午的 Work 任务：41.9 分钟，消耗 $\approx 19.5\%$ （官方计数器口径），斜率 $\approx 0.47\%/分钟$ 。之后七个小时，本测量会话走 Code 通道持续工作，斜率 $\approx 0.02\%/分钟$ 。同一池额度，Code 通道的流速只有 Work 的几十分之一。




● Work 通道 (模型调用) ● iFinD 插件 (0.02%/次) ● Code 通道 (含本测量自身)

口径说明：曲线纵轴为**官方计数器口径**（形状取自 995 条计费流水，按 0% / 22.22%（14:09 API 实测）/ 25.35%（16:50）三点分段校准；任务终点 $\approx 19.5\%$ 为用户侧读数）。流水逐条合计比计数器高 2.6%——逐条 0.01% 量化+保底的累积膨胀，详见报告摘要第 13 条。

■ 费率校准

同一个 K3 模型，两套实测费率卡

官方 API 挂牌价 \$3.00/\$0.30/\$15.00 per M（按 1 USD ≈ ¥7.0 折算：¥21/¥2.1/¥105），但会员池内如何折算从未公示。我们用 18 个 Code 受控调用 + 2 个有机验证点、14 个 Work 受控回合与 160 对有机调用秒级配对，把两套费率逐一钉在刻度尺上（区间为 0.01% 量化网格下的可行域）：



缓存一项，两个产品相差 **22 倍**：Code 按官方缓存价的 4% 象征性收取（¥0.05~0.09/M，近免费），Work 按官方缓存价足额收取（¥1.60~2.10/M）。长程任务的 token 以缓存读为主——这一格刻度，决定长任务的真实成本结构。

■ 解剖实录

41.9 分钟，≈19.5%：一次 Work 任务的完整解剖

2026-09-21 上午，一个"Max effort"深度研究任务：15 个代理、254 条去重模型调用、1,518 万 tokens（93% 为缓存读）。计费流水逐条合计，这一次任务消耗 20.89%——而当日全天官方计数器仅 25.35%（流水合计 27.96%），即这一个任务吃掉了全天消耗的大部分。

官方自己的估算是多少？ 帮助页写明"一次深度研究 ≈ 5-10% 月度额度"；本次实测同类 Work 任务 ≈19.5%——官方估算上限的近 2 倍。



扣费去向（按 feature）	Work 模型扣费的 token 构成（¥146.7 推算）
Work 模型调用（250 步）14.57%	输出 31.1 万¥83.7
iFinD 数据源插件（317 次调用、309 次计费 × 0.02%）6.18%	新输入 102 万¥37.8
Code 问答（任务中穿插）0.14%	缓存读 1,386 万¥25.2
联网搜索（63 次）0（免费）	费率卡回测上午任务总扣费：预测 ¥146.7 vs 实扣 ¥145.7，偏差 +0.7%。

同样的 1,518 万 tokens 走 Code 通道只值 ¥47.2——Work 通道实扣 ¥145.7，3.1 倍。贵在三处：输出加价 2.6×、缓存照价收费、输入加价 1.8×。另有 iFinD 插件按次抽成 0.02%/次，任务前无任何提示。

■ 开 机 费

一句"收到"，¥1.10

每个新 Work 会话开局即装载约 2.9 万 tokens 的系统提示词，按 1.8× 官方价计入——无论你说什么。受控实验里，两个字的回复比一篇 2,000 字长文贵 3.7 倍：

会话 A ·「只回答两个字：收到」		会话 B ·「写一篇 2,000 字说明文」	
未命中输入（系统提示词 2.9 万）	29,271 tok	未命中输入（增量）	186 tok
输出（"收到"）	41 tok	缓存读 + 输出全文	29,184 + 1,055 tok
实扣		0.11% ≈ ¥1.10	0.03% ≈ ¥0.30

■ 购 买 力 测 算

同一张 ¥199，三条通道三种买力

额度池按 API 标价锚定 ¥1,000。但同样的池子，走不同通道能买到的实际算力不同（按实测费率与 98% 缓存结构推算）：

纯 Code 通道 输入 63 折 + 缓存近免费		≈ ¥2,540
纯 Work 通道 三项加价后的标价换算		≈ ¥570
Work + iFinD 混合 上午任务的真实结构		≈ ¥397

折算会员费口径的有效单价：Code 通道 ¥0.27/M tokens，Work 通道 ¥1.91/M——相差 7 倍。轻度使用的 Code 订阅依然划算；问题从来不在价格水平，而在用户无法在任务开始前预知成本。

■ 行业坐标

透明度阶梯上的位置

产品	额度制度	透明度	关键差异
小米 MiMo Token Plan	订阅 + token 包	高	逐 token 系数表全公开，五家唯一
智谱 GLM Coding Plan	积分制 (token×系数/10000)	中	公式公开，但接口只回百分比
OpenAI Codex / Anthropic Claude	固定月费 + 时间窗限速	中	无月度死池；窗口内用量不透明但制度可预期
Manus	积分制 (\$20 = 4,000 credits)	低	官方自认"成本难以预测"
Devin	ACU 制 (\$2.25/ACU ≈ 15 分钟)	低	社区批评"不透明、不可预测的 ACU 计费"
Kimi Allegretto	月度共享死池 (实测 ¥1,000 标价池；官方档位口径"Agent 档 4 倍")	低	仅百分比进度条；双费率卡未公示；插件按次抽成无提示 (本报告实测)

■ 证据强度

每个数字都可以复算

20/20 Code 实验点 (18 受控+2 有机) 全部落量化带	14/14 Work 受控方程 RMSE ¥0.028 = 噪声下限	160 有机调用秒级配对 (缓存价交叉验证)	+0.7% 上午任务回测偏差 (¥146.7 vs ¥145.7)
--	--	--	---

原始数据 [data/](#) · 复现脚本 [scripts/](#) · 独立审计 [research/](#) · 主报告 [REPORT.md](#)

免 责 与 边 界 声 明

- 本页为**个人消费计量研究**：付费用户测量自己账号的消费记录，属消费者知情权范畴；不构成对任何主体的指控，亦不构成法律意见。
- 费率卡为**有限信息下的数学反演**：全部给出量化区间而非单点断言；凡属解释性内容（如商业逻辑推测）在报告中均已单独标注为推测。
- 测量范围为单一账号、单档位、K3 High 模式、2026-09-21 当日；官方可随时调整计费规则，届时本报告相应内容转为历史记录。
- 测量误差受 0.01% 计费量化网格限制（单次最小分辨 ¥0.10）；我们以区间交集与总量回测双重控制该误差。
- 官方对 Allegretto 档位的宣传口径为"Agent 档额度的 4 倍"（档位间相对值）；本报告的"¥1,000 标价池 / 5.03×"为实测推算，两者口径不同，均已如实标注。截至测量日，官方未公示任何档位的额度绝对值与池内费率。
- 本报告所用接口路径此前已有社区记录，我们的增量是受控实验费率卡与双通道发现；外部价格事实经独立调研核验（[核验记录](#)）。
- 全部原始数据（脱敏后）与拟合脚本随仓库公开，欢迎复核与复现；方法见 [METHOD.md](#)。

完整报告 [REPORT.md](#) · 技术附录 [TECHNICAL.md](#) · 复现指南 [METHOD.md](#)

测量与撰写：Kimi K3（DeepSeek Harness） · 受控实验与审校：人类付费用户 · 2026-09-21



