

报告编号 No. 2026-0921-K3

测量日期 2026-09-21

计量对象 Kimi 会员额度计费系统 (Allegretto ¥199/月 · 老套餐)

K3  
实测

计 量 校 准 证 书

## Kimi 会员额度计费黑盒实测

揭示百分比进度条背后的点卡账本：月度池真实价值、Code 与 Work 两套未公示费率、以及一次 41.9 分钟任务如何蒸发掉月度额度的  $\approx 19.5\%$ 。

测量与撰写：Kimi K3 模型 (k3-agent, 于 DeepSeek Harness 代理框架) · 受控实验执行与审校：人类付费用户  
—— 被计费的模型，测量了计费它自己的系统 ——

|                                                                                  |                                                      |                                                   |                                                                            |
|----------------------------------------------------------------------------------|------------------------------------------------------|---------------------------------------------------|----------------------------------------------------------------------------|
| <b>10,000 credits</b><br>月度额度池 (1 credit = 0.01%)<br>锚点折算 $\equiv$ ¥1,000 API 标价 | <b>22×</b><br>缓存计费差距<br>Code ¥0.08/M vs Work ¥1.82/M | <b>2.6×</b><br>Work 输出加价<br>实测 ¥270/M (官方标价 ¥105) | <b><math>\approx 19.5\%</math></b><br>一次 41.9 分钟 Work 任务<br>蒸发月度额度 (计数器口径) |
|----------------------------------------------------------------------------------|------------------------------------------------------|---------------------------------------------------|----------------------------------------------------------------------------|

### ■ 一 卡 读 懂

#### 你的 ¥199 买到的是 10,000 credits 点卡

官方界面仅展示一根百分比进度条。依据计费流水 0.01% 最小颗粒度，全池记为 **10,000 credits** (1 credit = 0.01% 进度条一格)。按官方 API 目录价锚定，**1 credit  $\equiv$  ¥0.10**，整包点卡对应 **¥1,000** 目录价算力。

|                                  |             |                                           |
|----------------------------------|-------------|-------------------------------------------|
| 基准标尺<br>全按官方目录输出价使用              | <div></div> | <b>¥1,000 (1.00×</b>                      |
| 走 Kimi Code<br>输入 63 折 + 缓存近乎免单  | <div></div> | <b><math>\approx</math> ¥2,540 (2.54×</b> |
| 走 Kimi Work<br>输出加价 2.6× + 缓存原价  | <div></div> | <b><math>\approx</math> ¥570 (0.57×</b>   |
| Work + iFinD 插件<br>41.9 分钟深度任务实测 | <div></div> | <b><math>\approx</math> ¥397 (0.40×</b>   |

**同一包额度，含金量差 6.4 倍：**同一个 K3 模型、同一池额度，走 Code 换得 **¥2,540** 算力，而走 Work+iFinD 仅换得 **¥397** 算力。额度不是固定价值单位，而是随产品通道大幅浮动的积分。

同一个 K3 模型，两套实测费率卡

通过 18 个 Code 受控调用、14 个 Work 受控回合 与 160 对有机调用秒级配对，钉死两套真实费率：

| ① 未命中输入 (Prompt Input) |             |                 | 单位: ¥ / 百万 tokens |
|------------------------|-------------|-----------------|-------------------|
| 官方目录价                  | <div></div> | ¥21.0 (基准)      |                   |
| Code 实测                | <div></div> | ¥13.3 (63 折)    |                   |
| Work 实测                | <div></div> | ¥37.2 (1.8× 加价) |                   |

| ② 缓存读取 (Cache Hit · 核心差距) |             |                | 单位: ¥ / 百万 tokens |
|---------------------------|-------------|----------------|-------------------|
| 官方目录价                     | <div></div> | ¥2.10 (基准)     |                   |
| Code 实测                   | <div></div> | ¥0.08 (4% 近免费) |                   |
| Work 实测                   | <div></div> | ¥1.82 (≈ 官方原价) |                   |

| ③ 模型输出 (Output · 含思考 Token) |             |                  | 单位: ¥ / 百万 tokens |
|-----------------------------|-------------|------------------|-------------------|
| 官方目录价                       | <div></div> | ¥105.0 (基准)      |                   |
| Code 实测                     | <div></div> | ¥105.0 (同价)      |                   |
| Work 实测                     | <div></div> | ¥269.6 (2.6× 加价) |                   |

**缓存相差 22 倍，输出加价 2.6 倍：**长程任务中缓存占 90% 以上，Code 缓存近乎免单，而 Work 按官方价足额收取；加上输出加价 2.6×，导致 Work 扣费速度呈现量级跃升。

一句“收到”，扣除 ¥1.10 额度

| 会话 A ·「只回复两个字：收到」 |                 | 会话 B ·「写 2,000 字长文」 |                    |
|-------------------|-----------------|---------------------|--------------------|
| 装载系统提示词 (未命中输入)   | 29,271 tok      | 增量未命中输入             | 186 tok            |
| 模型输出 ("收到" + 思考)  | 41 tok          | 缓存读取 + 输出全文         | 29,184 + 1,055 tok |
| 实扣额度              | 0.11% (≈ ¥1.10) | 实扣额度                | 0.03% (≈ ¥0.30)    |

**两个字比两千字贵 3.7 倍：**每个新 Work 会话默认预装载约 2.9 万 tokens 系统词并按 1.8× 费率计费。单次任务内长程对话因高缓存复用而划算，盲目频繁新开会话反而导致开机费剧增。

## 41.9 分钟，蒸发 ≈19.5% 额度：Work 任务深度解剖

用户一句「Max effort 行动吧」触发 14 代理 Swarm 并发，完成 254 次调用、1,518 万 tokens。官方帮助页估算同类深度任务约 5–10%，实测消耗达到 ≈19.5%（近 2 倍）。

全月 10,000 credits 额度池扣除流向

单次任务实耗 ≈19.5%（约 1,950 credits）



| 扣费结构拆解                                                       | Work 模型内部 Token 构成 (¥146.7 标价)                |
|--------------------------------------------------------------|-----------------------------------------------|
| <div>■ Work 模型推理 (250 步) 14.57% (1,457 credits)</div>        | 输出 31.1 万 <div></div> ¥83.7 (57%)             |
| <div>■ iFinD 数据源 (309 次计费 × 0.02%) 6.18% (618 credits)</div> | 新输入 102 万 <div></div> ¥37.8 (26%)             |
| <div>■ Code 穿插调用 (14 次) 0.14% (14 credits)</div>             | 缓存 1,386 万 <div></div> ¥25.2 (17%)            |
| <div>■ 联网搜索 (63 次调用) 0% (无单独扣费)</div>                        | iFinD 插件按次固定抽 0.02%/次；联网搜索无单独抽成（内容计入模型输入上下文）。 |

## 每个数字均可独立复现

|                             |                                          |                              |                                           |
|-----------------------------|------------------------------------------|------------------------------|-------------------------------------------|
| 20/20<br>Code 实验点<br>全部落可行域 | 14/14<br>Work 受控方程<br>RMSE ¥0.028 (噪声下限) | 160 对<br>有机调用秒级配对<br>缓存价交叉验证 | +0.7%<br>任务回测偏差<br>预测 ¥146.7 vs 实扣 ¥145.7 |
|-----------------------------|------------------------------------------|------------------------------|-------------------------------------------|

### 免责与边界声明

- 本页为个人消费计量研究：付费用户测量自己账号的消费记录，属消费者知情权范畴；不构成对任何主体的指控。
- 费率卡为有限信息下的数学反演：给出量化可行域而非单点断言；Work 分项费率由 14 方程区间交集与回测双重锁定。
- 测量对象为单一账号、K3 模式、2026-09-21 Allegretto 老套餐；新套餐（Plus/Pro）费率请参考 METHOD.md 实测。
- 全部脱敏数据与复算脚本完全开源：详见 [REPORT.md](#) 与 [METHOD.md](#)。