

报告编号 No. 2026-0921-K3

测量日期 2026-09-21

计量对象 Kimi 会员额度计费系统 (Allegretto ¥199/月 · 老套餐)



计 量 校 准 证 书

Kimi 会员额度计费黑盒实测

一根只显示百分比的进度条背后：月度额度池的真实价值、Code 与 Work 两套未公示的费率、以及一次 41.9 分钟的任务如何蒸发掉月度额度的 $\approx 19.5\%$ 。

测量与撰写：Kimi K3 模型 (k3-agent, 于 DeepSeek Harness 代理框架) · 受控实验执行与审校：人类付费用户

—— 被计费的模型，测量了计费它自己的系统 ——

本证书由 K3 自主完成；人类仅提供账号、电费与方向性点头。如内容有异议，请直接约谈 K3——约谈它也走贵司额度。

10,000

credits

月度额度池 (1
credit = 0.01%)
实测汇率 1 credit =
¥0.10 API 标价

22×

缓存计费差距
Code ¥0.08/M vs
Work ¥1.82/M

2.6×

Work 输出加价
实测 ¥263~272/M
(官方 ¥105)

$\approx 19.5\%$

一次 41.9 分钟的
Work 任务
蒸发的月度额度 (计
数器口径)

你的 ¥199，是一包 10,000 credits 的点卡

积分流水卡·Allegretto（老套餐）	
你付出	¥199 / 月（固定）
你得到	10,000 credits（本报告刻度；1 credit = 0.01% 池）
数量：月度额度（1 credit = 0.01%，进度条一格）	10,000 credits
换算率：按官方 API 目录价折算	1 credit $\equiv$ ¥0.10
标价：10,000 credits $\times$ ¥0.10	$\approx$ ¥1,000
基准：全按官方输出价使用	1.00 $\times$ = ¥1,000
走 Code：缓存近乎免费 + 输入 63 折	2.54 $\times$ $\approx$ ¥2,540
走 Work：输出加价 2.6 $\times$ + 缓存放原价 + 开机费	0.57 $\times$ $\approx$ ¥570
Work + iFinD 实跑一次任务（41.9 分钟）	0.40 $\times$ $\approx$ ¥397
同一包积分，含金量相差 6.4 倍	0.40 $\times$ $\sim$ 2.54 $\times$

Kimi 会员计费的三层结构

先把计费这件事本身说清楚，再看测量结果。

01 你付的钱，和你看到的東西

¥199/月固定，用多用少都是这个价。换来的只有一根 0~100% 的百分比条——官方公布档位间的相对倍率与粗略任务数估算，没有绝对 token 数、没有人民币折算、没有分项费率。

02 扣费的方式

每次调用： $\text{tokens} \times \text{通道费率}$ ，折算成 credits 从池中扣除（1 credit = 0.01% 取整，单次最低 1 credit）。**Code 与 Work 是两套不同的费率**——这就是本报告测出来的东西。

换算（10,000 credits $\equiv$ ¥1,000 目录价、各通道含金量 $0.40 \times \sim 2.54 \times$ ）见上一节积分流水卡；下文所有「¥」都是目录价折算，不是你的实付。

为什么同一件事有两种价格？ 因为"通道费率"从未公示。同一个 K3 模型、同一池额度，走 Code 通道便宜，走 Work 通道贵——缓存一项相差 22 倍。下面把两套费率逐一校准。

算例·一次扣费的诞生（受控实验 W2 实录）

输出 1,055 tok $\times$ Work 输出价 ¥0.28
¥270/M

缓存读 29,184 tok $\times$ Work 缓存价 ¥0.05
¥1.82/M

新输入 186 tok $\times$ Work 输入价 ¥0.01
¥37.2/M

合计（标价口径） $\rightarrow \div \text{¥10}$ ¥0.34 $\rightarrow$
换算 $\rightarrow$ 量化取整 0.034%

从池中实扣 **0.03%**

两个"钱"的口径，别混


标价口径（口径 A）：池子的内部记账单位。说"这次扣费 ¥1.10"，意思是"相当于 ¥1.10 的官方 API 标价"——用来比较通道与任务的相对成本。本页的 ¥ 默认此口径。

实付口径（口径 B）：你真实付出的固定 ¥199/月。走 Code 通道，这 ¥199 约买到 ¥2,540 标价算力；走 Work+iFinD，只买到约 ¥397（见购买力测算）。

■ 消耗曲线

一天的两种速度

计费周期当天重置。上午的 Work 任务：41.9 分钟，消耗 $\approx 19.5\%$ （官方计数器口径），斜率 $\approx 0.47\%$ /分钟。之后七个小时，本测量会话走 Code 通道持续工作，斜率 $\approx 0.02\%$ /分钟。同一池额度，Code 通道的流速只有 Work 的几十分之一。




口径说明：曲线纵轴为**官方计数器口径**（形状取自 995 条计费流水，按 0% / 22.22%（14:09 API 实测） / 25.35%（16:50）三点分段校准；任务终点 $\approx 19.5\%$ 为用户侧读数）。流水逐条合计比计数器高 2.6%——逐条 0.01% 量化+保底的累积膨胀，详见报告摘要第 13 条。

费率校准

同一个 K3 模型，两套实测费率卡

官方 API 挂牌价 \$3.00/\$0.30/\$15.00 per M（按 1 USD $\approx$ ¥7.0 折算：¥21/¥2.1/¥105），但会员池内如何折算从未公示。我们用 18 个 Code 受控调用 + 2 个有机验证点、14 个 Work 受控回合与 160 对有机调用秒级配对，把两套费率逐一钉在刻度尺上（区间为 0.01% 量化网格下的可行域）：



缓存命中

¥/M tokens · 对数刻度



输出

¥/M tokens · 对数刻度



● Kimi Code 实测（点解 + 区间须线） ● Kimi Work 实测（点解 + 区间须线）

□ 官方 API 公开价

缓存一项，两个产品相差 **22 倍**：Code 按官方缓存价的 4% 象征性收取（¥0.05~0.09/M，近免费），Work 按官方缓存价足额收取（¥1.60~2.10/M）。**长程任务的 token 以缓存读为主——这一格刻度，决定长任务的真实成本结构。**

■ 解剖实录

41.9 分钟，≈19.5%：一次 Work 任务的完整解剖

2026-09-21 上午，一个"Max effort"深度研究任务：15 个代理、254 条去重模型调用、1,518 万 tokens（93% 为缓存读）。这一次任务消耗 2,089 credits（流水口径 20.89% ≈ 计数器口径 19.5%；口径差异见上一节曲线说明）——当日全天官方计数器也只有 25.35%，即这一个任务吃掉了全天消耗的大部分。

官方自己的估算是多少？ 帮助页写明"一次深度研究 ≈ 5-10% 月度额度"；本次实测同类 Work 任务 **≈19.5%**——官方估算上限的近 2 倍。

月度额度池消耗构成

流水合计 20.89%

扣费去向 (按 feature)

Work 模型调用 (250 步) **14.57%**iFinD 数据源插件 (317 次调用、**6.18%**
309 次计费 $\times$ 0.02%)Code 问答 (任务中穿插) **0.14%**联网搜索 (63 次) **0 (免费)**

Work 模型扣费的 token 构成 (¥146.7 推算)

输出 31.1 万  **¥83.7**新输入 102 万  **¥37.8**缓存读 1,386 万  **¥25.2**费率卡回测上午任务总扣费: 预测 ¥146.7 vs
实扣 ¥145.7, 偏差 +0.7%。

同样的 1,518 万 tokens 走 Code 通道只值 **¥47.2**——Work 通道实扣 **¥145.7**, 3.1 倍。贵在三处: 输出加价 2.6 $\times$ 、缓存照价收费、输入加价 1.8 $\times$ 。另有 iFinD 插件按次抽成 0.02%/次, 任务前无任何提示。

■ 开 机 费

一句"收到", ¥1.10

每个新 Work 会话开局即装载约 2.9 万 tokens 的系统提示词, 按 1.8 $\times$ 官方价计入——无论你说什么。受控实验里, 两个字的回复比一篇 2,000 字长文贵 3.7 倍:

会话 A ·「只回答两个字: 收到」

未命中输入 (系统提示词 2.9 29,271
万) tok

输出 ("收到") 41 tok

实扣 0.11% $\approx$ ¥1.10

会话 B ·「写一篇 2,000 字说明文」

未命中输入 (增量) 186 tok

缓存读 + 输出全 29,184 + 1,055
文 tok**实扣 0.03% $\approx$ ¥0.30**

■ 购买力测算

买力差的后果：同一池额度，单价相差 7 倍

三条通道各能换到多少目录价算力，已列在[积分流水卡](#)（ $2.54\times / 0.57\times / 0.40\times$ ）。把它折算成会员费口径的**有效 token 单价**：Code 通道 ¥0.27/M tokens，Work 通道 ¥1.91/M——相差 7 倍。

轻度使用的 Code 订阅依然划算；**问题从来不在价格水平，而在用户无法在任务开始前预知成本**——同一个"行动吧"，在 Code 里值 ¥0.27/M，在 Work 里值 ¥1.91/M，而界面上只有一个百分比。

■ 行业坐标

透明度阶梯上的位置

同类产品里，小米 MiMo 逐 token 系数表全公开，智谱 GLM 公式公开（接口只回百分比），OpenAI / Anthropic 用时间窗限速、不设月度死池，Manus 与 Devin 虽为黑盒积分/ACU 制但至少公开了换算关系。**Kimi 是唯一同时存在"黑盒百分比 + 月度死池 + 按次抽成插件 + 无预算保护"的产品**——但需客观指出：池内定价在轻度使用下是五家中最划算的之一，问题在不可预知性，不在价格水平。
六家完整对比表（含官方来源 URL）见 [REPORT.md](#) §7。

■ 证据强度

每个数字都可以复算

20/20 Code 实验点（18 受控+2 有机）全部量化带	14/14 Work 受控方程 RMSE ¥0.028 = 噪声下限	160 有机调用秒级配对（缓存价交叉验证）	+0.7% 上午任务回测偏差（¥146.7 vs ¥145.7）
---	--	---	--

免 责 与 边 界 声 明

1. 本页为**个人消费计量研究**：付费用户测量自己账号的消费记录，属消费者知情权范畴；不构成对任何主体的指控，亦不构成法律意见。
2. 费率卡为**有限信息下的数学反演**：给量化区间而非单点断言，解释性内容（如商业逻辑推测）均单独标注为推测；测量误差受 $0.01\% = 1 \text{ credit}$ 量化网格限制（单次最小分辨 $\approx \text{¥}0.10$ 目录价），我们以区间交集与总量回测双重控制。
3. 测量范围为单一账号、单档位、K3 High 模式、2026-09-21 当日；官方可随时调整规则，届时本文转为历史记录。官方"Agent 档 4 倍"是档位间口径，与本报告的换算率（ $10,000 \text{ credits} \approx \text{¥}1,000 \text{ 目录价} / 5.03\times$ ）不是同一口径，均已标注。
4. 全部脱敏数据与拟合脚本随仓库公开，欢迎复核；接口路径此前已有社区记录（[核验记录](#)）。完整边界、方法与勘误见 [REPORT.md](#) 免责声明与 [METHOD.md](#)。

⌚ **时效标注**：本证书测量的是 2026-09-21 的 **Allegretto 老套餐**。此后官方上线新套餐体系（Plus/Pro 等，以官方公示为准），费率或已变化——欢迎用 [METHOD.md](#) 的方法实测新套餐，这正是本仓库开源的目的。

